
Machine Learning HW2

MLTAs

mlta2019fall@gmail.com

Outline

- HW2 - Income 50K prediction
 - Dataset and Tasks Description
 - Provided Feature Format
 - Sample Submission
- Kaggle
- Grading / Assignment Regulation

Dataset and task introduction

- Dataset : Adult Data Set

Reference : <https://archive.ics.uci.edu/ml/datasets/Adult>

- Task : **Binary Classification**
 - **Logistic regression, Probabilistic generative model**

Determine whether a person makes over 50K a year.

Data Attribute Information

train.csv 、 **test.csv** :

age, workclass, fnlwgt, education, education num, marital-status, occupation
relationship, race, sex, capital-gain, capital-loss, hours-per-week,
native-country, make over 50K a year or not

```
1 39, State-gov, 77516, Bachelors, 13, Never-married, Adm-clerical, Not-in-family, White, Male, 2174, 0, 40, United-States, <=50K
2 50, Self-emp-not-inc, 83311, Bachelors, 13, Married-civ-spouse, Exec-managerial, Husband, White, Male, 0, 0, 13, United-States, <=50K
3 38, Private, 215646, HS-grad, 9, Divorced, Handlers-cleaners, Not-in-family, White, Male, 0, 0, 40, United-States, <=50K
4 53, Private, 234721, 11th, 7, Married-civ-spouse, Handlers-cleaners, Husband, Black, Male, 0, 0, 40, United-States, <=50K
5 28, Private, 338409, Bachelors, 13, Married-civ-spouse, Prof-specialty, Wife, Black, Female, 0, 0, 40, Cuba, <=50K
6 37, Private, 284582, Masters, 14, Married-civ-spouse, Exec-managerial, Wife, White, Female, 0, 0, 40, United-States, <=50K
7 49, Private, 160187, 9th, 5, Married-spouse-absent, Other-service, Not-in-family, Black, Female, 0, 0, 16, Jamaica, <=50K
8 52, Self-emp-not-inc, 209642, HS-grad, 9, Married-civ-spouse, Exec-managerial, Husband, White, Male, 0, 0, 45, United-States, >50K
```

- More detail please check out Kaggle Description Page

Sample Submission

請預測test set中16281筆資料

1. 上傳格式為csv
2. 第一行必須為id,label, 第二行開始為預測結果
3. 每行分別為id以及預測的label, 請以逗號分隔
4. Evaluation: Accuracy

```
1 id,label
2 1,0
3 2,0
4 3,0
5 4,1
6 5,0
7 6,1
8 7,1
9 8,1
10 9,0
11 10,0
```

Kaggle Info & Deadline

- Link: [ML2019fall HW2 Income prediction](#)
- 個人進行、不須組隊
- Team Name:
 - 修課學生: 學號_任意名稱 (ex: b09901666_大助好帥)
 - 旁聽: 旁聽_任意名稱
- Maximum Daily Submission: 5 times
- Simple Baseline Deadline: 10/17/2019 23:59:59 (GMT+8)
- Kaggle Deadline: 10/24/2019 23:59:59 (GMT+8)
- Github Deadline: 10/26/2019 23:59:59 (GMT+8)
- test set的16281筆資料將被分為兩份, 8140筆public, 8141筆private
- Leaderboard上所顯示為public score, 在Kaggle Deadline前可以選擇2份submission作為private score的評分依據。

配分 Grading Criteria - kaggle (5% + Bonus 1%)

- Kaggle Deadline : 10/24/2019 23:59:59 (GMT+8)
- Early Baseline Point - 1%
 - 在 10/17/2019 23:59:59 (GMT+8) 前於 **public scoreboard** 通過 **early baseline** : 1%
- Private Score Point - 4%
 - 以 10/24/2019 23:59:59 於 **public/private scoreboard** 之分數為準：
 - 超過public leaderboard的simple baseline分數：1%
 - 超過public leaderboard的strong baseline分數：1%
 - 超過private leaderboard的simple baseline分數：1%
 - 超過private leaderboard的strong baseline分數：1%
 - 以上皆須通過 Reproduce 才給分
- Bonus - 1%
 - (1.0%) private leaderboard 排名前五名且於助教時間上台分享的同學

配分 Grading Criteria - report(5%)

- Programming Report - 2%
 - https://docs.google.com/document/d/1ROAFfY7AuVoCPOIpbMCQizwGTj-YFKS2JE_39XJ2Wuc/edit
- Math Problem - 3%
 - <https://hackmd.io/RFiu1FsYR5uQTrrpdxUvIw?both>
 - Type in latex(preferable) or take pictures of your handwriting
- Write them in report.pdf

作業規定 Assignment Regulation

1. 請**手刻** gradient descent 實作 logistic regression
2. 請**手刻**實作 probabilistic generative model
3. hw2_logistic.sh、hw2_generative.sh、hw2_best.sh皆須在5分鐘內跑完
4. **Only Python 3.6 available !!!!**
5. hw2_logistic.sh、hw2_generative.sh 開放使用套件
 - a. numpy == 1.16.5
 - b. scipy == 1.3.1
 - c. pandas == 0.25.1
 - d. python standard library
6. hw2_best.sh不限做法, 開放以下套件(但有版本限制請注意)
 - a. pytorch == 1.2.0
 - b. tensorflow == 1.14.0
 - c. keras == 2.2.4
 - d. scikit-learn == 0.21.3
 - e. 不可以使用 xgboost, AdaBoostClassifier, ExtraTreesClassifier
7. 若需使用其他套件, 請儘早寄信至助教信箱詢問, 並請闡明原因。

Github Submissions

你的github上ML2019FALL/hw2/**至少**有下列4個檔案(格式必須完全一樣):

1. **hw2_logistic.sh** : handcraft "logistic regression" using Gradient Descent
2. **hw2_generative.sh** : handcraft "probabilistic generative model"
3. **hw2_best.sh** : meet the highest score you choose in kaggle
4. **report.pdf** : Please refer to report template

hw2_logistic.sh **or** hw2_generative.sh **should beat public simple baseline**

請不要上傳dataset, 請不要上傳dataset, 請不要上傳dataset

Shell script

助教在批改程式部分時，會執行以下指令：

`bash ./hw2_logistic.sh $1 $2 $3 $4 $5 $6` output: your prediction

`bash ./hw2_generative.sh $1 $2 $3 $4 $5 $6` output: your prediction

`bash ./hw2_best.sh $1 $2 $3 $4 $5 $6` output: your prediction

\$1: raw data (train.csv) \$2: test data (test.csv)

\$3: provided train feature (X_train) \$4: provided train label (Y_train)

\$5: provided test feature (X_test) \$6: ans.csv

上述提供的input大家可以不用全部都使用

Shell script

- 請務必在訓練過程中，隨時存取參數
- test data會shuffle過，請勿直接輸出事先存取的答案
- hw2 shell script皆需要在5分鐘內執行完畢，否則該部分將以0分計算
- 切勿於程式內寫死輸入檔案是output file的路徑，否則該部分將以0分計算
- Script所使用之模型，如npz檔、pickle檔等，可以於程式內寫死路徑，助教會cd進hw2資料夾執行reproduce程序
- [Conda file](#) (同學可自行下載改prefix測試)

Report 格式

- 限制
 - 檔名必須為 report.pdf !!!
 - 檔名必須為 report.pdf !!!
 - 檔名必須為 report.pdf !!!
 - 請用中文撰寫report(非中文母語者可用英文)
 - 請標明系級、學號、姓名，並按照report模板回答問題，切勿隨意更動題號順序
 - 若有和其他修課同學討論，請務必於題號前標明 collaborator(含姓名、學號)
- Report模板連結
 - 連結：[Link](#)
- 截止日期同 Github Deadline: 10/26/2019 23:59:59 (GMT+8)

其他規定 Other Policy

- Lateness
 - Github每遲交一天(不足一天以一天計算) hw1所得總分將x0.7
 - 不接受程式 or 報告單獨遲交
 - 不得遲交超過一天, 若有特殊原因請儘速聯絡助教
 - Github遲交表單: 遲交請先上傳遲交檔案至自己的github後再填寫遲交表單, 助教群會以表單填寫時間作為繳交時間手動 clone檔案。
 - 表單連結: [Link](#) (遲交才必需填寫)
- Script Error
 - 當script格式錯誤, 造成助教無法順利執行, 請在公告時間 內寄信向助教說明, 修好之後重新執行所得kaggle部分分數將x0.7。
 - 可以更改的部分僅限 syntax及io的部分, 不得改程式邏輯或是演算法, 至於其他部分由助教認定為主。
 - 只能在助教面前更改你的 script。

其他規定 Other Policy



- Cheating

- 抄code、抄report (含之前修課同學)
- 開設kaggle多重分身帳號註冊competition
- 於訓練過程以任何不限定形式接觸到testing data的正確答案
- 填寫前人的github repo url
- 不得上傳之前的kaggle競賽
- 教授與助教群保留請同學到辦公室解釋coding作業的權利, 請同學務必自愛

TA Hour

- 10/18 助教課 手把手教學
- 10/15, 10/22 (Tue) @BL530
- AM09:20~PM12:00